

Matias Fuentes

Reporting & Data Analyst | Business Intelligence

Olavarría, AR · Gmail · Portfolio · LinkedIn

Perfil profesional

Analista de Datos con especialización en Business Intelligence y Reporting, con experiencia en el procesamiento y análisis de datasets reales provenientes de e-commerce y retail. Especializado en el diseño de tableros estratégicos (Power BI) y en la limpieza de datos complejos. Domino el flujo de datos desde la extracción (SQL) hasta la visualización, transformando información cruda en métricas accionables para la toma de decisiones.

Habilidades

Lenguajes y Bases de Datos: SQL (PostgreSQL, BigQuery) · Modelado de datos relacionales · Star Schema
BI & Visualización: Power BI (DAX, M, modelado, ETL) · Looker Studio · Excel avanzado (Power Query, tablas dinámicas) · Dashboards y reporting · Machine Learning (modelos predictivos)
Análisis de Datos: Python (Pandas, NumPy, Scikit-learn) · Segmentación RFM · Análisis de cohortes · Optimización de márgenes · KPIs de negocio · Análisis de embudos de conversión · AOV · Revenue analytics
Blandas: Pensamiento analítico · Comunicación de insights · Orientación a resultados
Herramientas y Entornos: Google Cloud, GitHub (control de versiones)
Idiomas: Español (Nativo), Inglés Técnico (Nivel A2/B1 - En desarrollo).

Experiencia profesional

Consultor de Datos & BI (Independiente) | Dic 2025 – Ago 2026

- **Auditoría de Comportamiento Financiero — Inclusión Digital** | Dataset: *Global Findex Microdata*
Stack Técnico: *Python (Pandas · Matplotlib/Seaborn)* · Trazabilidad, IA (*Copiloto analítico*)
 - Analicé 144.000+ encuestas individuales de Brasil (Global Findex, Banco Mundial) aplicando ponderación poblacional (wgt) para identificar patrones de ahorro representativos, tras detectar y corregir un error de agregación en una primera iteración del análisis.
 - Detecté que la brecha de ahorro por género (28.3%) iguala en magnitud a la brecha por ingreso (30.8%): un hombre joven del quintil más pobre ahorra más (63.9%) que una mujer del quintil más rico (53.2%).
 - Cuantifiqué el "Digital Premium" (74.8% vs 32.4% de ahorro según acceso a billetera digital, +42 p.p.) y propuse un piloto de ahorro automático (Redondeo Pix) para validar su impacto real.
- **Modelo Predictivo de Propensión de Compra** | Dataset: *Retail Rocket*
Stack Técnico: *Python (Scikit-learn, Random Forest, Pandas · Machine Learning)* · IA (*Copiloto analítico*)
 - Desarrollé un pipeline en Python de Random Forest sobre 300K+ usuarios, logrando un ROC-AUC de 0,81 y una reducción del 89% en falsos positivos mediante la optimización del umbral de decisión.
 - Implementé estrategias de undersampling y ventanas temporales estrictas para prevenir el data leakage; la optimización permitió mantener la detección del 47% de compradores reales, logrando un balance operativo viable para enfocar campañas de conversión.
- **Análisis de Rentabilidad Comercial — Retail** | Dataset: *Maven Analytics (AdventureWorks)*
Stack Técnico: *Microsoft Excel (Tabla dinámica, Modelado)* · IA (*Copiloto analítico*)
 - Desarrollé dashboard ejecutivo en Microsoft Excel con análisis de rentabilidad por subcategoría, región y período, identificando que el 98.3% del revenue se concentra en el Top 10 de productos y que Bikes pasó del 72% al 83% del mix en 3 años.
 - Detecté 3 subcategorías con \$1.39M en pérdidas sobre \$64.9M revenue y margen hasta -14% (Touring Bikes); revisión de costos/mix para evitar destrucción de profit.
 - Evalué la transición 2018→2019 (margen 3.22%→1.49% con +33% revenue y -75% profit); crecimiento impulsado por categorías de menor margen (revisión urgente del mix).
- **Análisis de Retención y Churn — E-commerce** | Dataset: *Online Retail UCI*
Stack Técnico: *Google BigQuery · SQL · Power BI (DAX)* · IA (*Copiloto analítico*)
 - Diseñé e implementé el modelo de datos (Esquema Estrella) en Google BigQuery, optimizando el procesamiento de +500K registros mediante vistas en SQL para el análisis de cohortes.
 - Construí 2 dashboards interactivos en Power BI integrando segmentación RFM, análisis de cohortes transaccionales y curvas de concentración de ingresos para identificar riesgos de pérdida de clientes.
 - Identifiqué un patrón de churn crítico en el Mes 1 (caída de retención del 100% al ~20%), proponiendo una estrategia de fidelización enfocada en los primeros 30 días para maximizar el Valor de Vida del Cliente (LTV).
 - Cuantifiqué el impacto de cancelaciones analizando el volumen de pedidos (17% de cancelaciones) contra el impacto real en ingresos (2% de pérdida), aislando ineficiencias operativas sin afectación crítica al margen neto.

Educación

Data Analyst & Data Scientist Tracks | DataCamp — 2025

Google Data Analytics Professional Certificate | Coursera — 2024